

GTI - Gestão e Análise de Dados

Professor Miguel Soares

2026-09-15

Contents

Sobre estas anotações	5
Calendário das aulas	5
Apresentação da Disciplina	9
1 - Dados com Ativo Estratégico: Introdução ao Machine Learning	11
1.1 - Exercícios - Dados com Atvo Estratégico: Introdução ao Machine Learning	11
2 - Governança de Dados e Ciclo de Vida de Machine Learning	13
2.1 - Governança de Dados e Ciclo de Vida de Machine Learning . .	13
3 Coleta de Dados e Regressão Linear	15
3.1 - Exercícios - Coleta de Dados e Regressão Linear	28
3.2 Questão 1	35
3.3 Questão 3	36
3.4 Questão 4	36
4 Gabarito	39
5 - Organização e Preparação dos Dados, Regressão Logística e KNN	41
5.1 - Exercícios - Organização e Preparação dos Dados, Regressão Logística e KNN	41
6 Gabarito	51

7 - Análise de Dados: Dilema Viés-Variância e Métricas de Avaliação	53
7.1 - Exercícios - Análise de Dados: Dilema Viés-Variância e Métricas de Avaliação	53
8 - Relatórios K.P.I. - Avaliação de Modelos e Árvores de Decisão	55
8.1 - Exercícios - Relatórios K.P.I. - Avaliação de Modelos e Árvores de Decisão	55
9 - Business Intelligence: Random Forest e Ensemble Learning	57
9.1 - Exercícios - Business Intelligence: Random Forest e Ensemble Learning	57
10 - Big Data e Support Vector Machines	59
10.1 - Exercícios - Big Data e Support Vector Machines	59
11 - Data Driven Decision Making e Redução de Dimensionalidade	61
11.1 - Exercícios - Data Driven Decision Making e Redução de Dimensionalidade	61
12 - Modelos de Gestão de Risco e Técnicas de Agrupamento	63
12.1 - Exercícios - Modelos de Gestão de Risco e Técnicas de Agrupamento	63
13 - Inteligência Artificial, Análise Preditiva e Seleção de Características	65
13.1 - Exercícios - Inteligência Artificial, Análise Preditiva e Seleção de Características	65
14 - Monitoramento Contínuo e Ciclo de Vida de Modelos de Machine Learning	67
14.1 - Exercícios - Monitoramento Contínuo e Ciclo de Vida de Modelos de Machine Learning	67

Sobre estas anotações

Calendário das aulas

0.0.0.0.1 AGOSTO DE 2026

Data	Dia da Semana	Aulas	Conteúdo
04/08/2026	Terça-Feira	Apresentação da disciplina	Apresentação do plano de ensino, objetivos, metodologia, avaliações e visão geral da disciplina
11/08/2026	Terça-Feira	Aula 01	Dados como ativo estratégico e Introdução ao Machine Learning
18/08/2026	Terça-Feira	Aula 02	Governança de Dados e ciclo de vida de Machine Learning
25/08/2026	Terça-Feira	Aula 03	Coleta de dados e Regressão Linear

0.0.0.0.2 SETEMBRO DE 2026

Data	Dia da Semana	Aulas	Conteúdo
01/09/2026	Terça-Feira	Aula 04	Organização e preparação dos dados, Regressão Logística e KNN

Data	Dia da Semana	Aulas	Conteúdo
08/09/2026	Terça- Feira	Aula 05	Análise de dados, dilema Viés-Variância e Métricas de Avaliação
15/09/2026	Terça- Feira	Aula 06	Relatórios, KPIs, avaliação de modelos e Árvores de Decisão
22/09/2026	Terça- Feira	NP1	PROVA
29/09/2026	Terça- Feira	Aula 07	Business Intelligence, Random Forest e Ensemble Learning

0.0.0.0.3 OUTUBRO DE 2026

Data	Dia da Semana	Aulas	Conteúdo
06/10/2026	Terça- Feira	Aula 08	Big Data e Support Vector Machines
13/10/2026	Terça- Feira	Aula 09	Data-Driven Decision Making e Redução de Dimensionalidade
20/10/2026	Terça- Feira	Aula 10	Modelos de gestão de riscos e técnicas de Agrupamento
27/10/2026	Terça- Feira	Aula 11	Inteligência Artificial, análise preditiva e Seleção de Características

0.0.0.0.4 NOVEMBRO DE 2026

Data	Dia da Sem- ana	Aulas	Conteúdo
03/11/2026	Terça- Feira	Aula 12	Monitoramento contínuo, melhoria de processos e ciclo de vida de modelos de Machine Learning
10/11/2026	Terça- Feira	NP2	PROVA
17/11/2026	Terça- Feira	SUB	PROVA SUBSTITUTIVA
24/11/2026	Terça- Feira	N/A	

0.0.0.0.5 DEZEMBRO DE 2026

Data	Dia da Semana	Aulas	Conteúdo
01/12/2026	Terça-Feira		N/A
08/12/2026	Terça-Feira	EXAME	PROVA

Apresentação da Disciplina

Chapter 1

- Dados com Ativo Estratégico: Introdução ao Machine Learning

1.1 - Exercícios - Dados com Atvo Estratégico: Introdução ao Machine Learning

Chapter 2

- Governança de Dados e Ciclo de Vida de Machine Learning

2.1 - Governança de Dados e Ciclo de Vida de Machine Learning

Chapter 3

Coleta de Dados e Regressão Linear

UNIP
UNIVERSIDADE PAULISTA

Aula 03 - Regressão Linear

Professor Miguél Suares

$$\hat{y} = wx + b$$

dados → modelo → previsão

UNIP • OTI - Oferta 2026 - Gestão e Análise de Dados

[Capítulo 14 Grus, 2015, p.]




Figure 3.1: Aula 03 - Coleta de Dados e Regressão Linear




Figure 3.2: Aula 03 - Coleta de Dados e Regressão Linear

Exemplo: aplicar a “formula” ou MODELO

Como o modelo já existe, não há aprendizado: há apenas cálculo.

$$f(x) = 2x + 10$$

$$y = 2x + 10$$


- Dado o modelo $y = 2x + 10$, calcule o valor para entrada **5**

$$x = 5$$

$$2 \cdot (5) + 10$$

$$y = 20$$

- Neste MODELO, para entrada $x=5$, a saída é $y=20$



Regressão Linear

03

Figure 3.3: Aula 03 - Coleta de Dados e Regressão Linear


Exemplo: aplicar a “formula” ou MODELO

Para o modelo abaixo, calcule as entradas a seguir:

$$y = 2x + 10$$

- Tabela de entradas:

x	y
1	12
2	14
3	16
4	18
5	20



Regressão Linear

03

Figure 3.4: Aula 03 - Coleta de Dados e Regressão Linear




Figure 3.5: Aula 03 - Coleta de Dados e Regressão Linear



Figure 3.6: Aula 03 - Coleta de Dados e Regressão Linear




Figure 3.7: Aula 03 - Coleta de Dados e Regressão Linear




Figure 3.8: Aula 03 - Coleta de Dados e Regressão Linear




Figure 3.9: Aula 03 - Coleta de Dados e Regressão Linear




Figure 3.10: Aula 03 - Coleta de Dados e Regressão Linear




Figure 3.11: Aula 03 - Coleta de Dados e Regressão Linear




Figure 3.12: Aula 03 - Coleta de Dados e Regressão Linear

Mas como calcular a Equação da Reta ?

Resposta: Método dos Mínimos Quadrados

$$\hat{y} = w * x + b \quad \Rightarrow \quad \hat{y} = (4,7) * x + b \quad \text{Agora falta descobrir o "b"}$$

$\bar{x}$ é a média de todos os "x" = 60

$\bar{y}$ é a média de todos os "y" = 310

"w" = 4,7

$$b = \bar{y} - w\bar{x} \quad \Rightarrow \quad b = 310 - (4,7)(60) \quad \Rightarrow \quad b = 28$$

Assim, nosso modelo fica:

$$\hat{y} = (4,7) * x + 28$$

Regressão Linear



69

Figure 3.13: Aula 03 - Coleta de Dados e Regressão Linear

Agora que temos nosso modelo, podemos responder

Quanto vale um apartamento de 65m² ?

Área (m ²)	Preço (R\$ mil)
40	220
50	260
60	310
65	?
70	350
80	410



Regressão Linear

67

Figure 3.14: Aula 03 - Coleta de Dados e Regressão Linear

Treinar é encontrar os valores de **w** e **b** que tornam as previsões o mais próximas possível dos valores reais.

[illegible]

```
import numpy as np
from sklearn.linear_model import LinearRegression
```



Figure 3.16: Aula 03 - Coleta de Dados e Regressão Linear




Figure 3.17: Aula 03 - Coleta de Dados e Regressão Linear



Figure 3.18: Aula 03 - Coleta de Dados e Regressão Linear




Figure 3.19: Aula 03 - Coleta de Dados e Regressão Linear



Figure 3.20: Aula 03 - Coleta de Dados e Regressão Linear



Figure 3.21: Aula 03 - Coleta de Dados e Regressão Linear

Vamos Descobrir um Modelo (Fórmula) usando Regressão Linear em PYTHON

Biblioteca python: `sklearn`

Pacote da Biblioteca sklearn: `sklearn.linear_model`

Função da Biblioteca: `LinearRegression()`

Regressão Linear 19

Figure 3.22: Aula 03 - Coleta de Dados e Regressão Linear

HÃO NA MASSA

Parte III — Mini-laboratório em Python

Objetivo: ajustar uma reta para prever preço a partir da área.

```
import numpy as np
from sklearn.linear_model import LinearRegression

X = np.array([[40], [50], [60], [70], [80]])
y = np.array([220, 260, 310, 350, 410])

modelo = LinearRegression()
modelo.fit(X, y)

print("O valor de w é: ", modelo.coef_)
print(f" A reta cruza toca o eixo X quando b vale: {modelo.intercept_}")
print(f"Quando X vale 65, a saída vale: {modelo.predict([[65]])}")
```

1. Treinar
`fit(X,y)`

2. Ler
`W → coef_`
`B → intercept_`

3. Predizer
`predict([[65]])`

Regressão Linear 20

Figure 3.23: Aula 03 - Coleta de Dados e Regressão Linear

```

X = np.array([[40], [50], [60], [70], [80]])
y = np.array([220, 260, 310, 350, 410])

# Crie o seu modelo
modelo = LinearRegression()

# Treine o seu modelo (ajuste sua reta aos pontos)
modelo.fit(X, y)

## LinearRegression()

#
print("O valor de W é: ", modelo.coef_)

## O valor de W é: [4.7]

print(f"O valor de b é {modelo.intercept_}")

## O valor de b é 28.0

# calcule: para um Apartamento de 65m2 qual é o valor previsto em mil reais ?
print(f"Quando X vale 65, a saída vale: {modelo.predict([[65]])}")

## Quando X vale 65, a saída vale: [333.5]

[Grus, 2015]

```

3.1 - Exercícios - Coleta de Dados e Regressão Linear

3.1.1 Exemplo 01 -

Uma pesquisa foi realizada com o objetivo de verificar se existe associação entre a falta de sono e a capacidade de as pessoas resolverem problemas simples. Foram testadas 10 pessoas, mantendo-se sem dormir por um determinado número de horas. Após cada um destes períodos, cada pessoa teve de resolver um teste com adições simples, anotando-se então os erros cometidos. Os dados resultantes são os seguintes:

3.1. - EXERCÍCIOS - COLETA DE DADOS E REGRESSÃO LINEAR 29

MÃO NA MASSA

Parte III — Mini-laboratório em Python

Use o Google Colab

<https://colab.research.google.com/>

```
import numpy as np
from sklearn.linear_model import LinearRegression

X = np.array([[40], [50], [60], [70], [80]])
y = np.array([220, 260, 310, 350, 410])

modelo = LinearRegression()
modelo.fit(X, y)

print("O valor de w é: ", modelo.coef_)
print(f" A reta cruza toca o eixo X quando b vale: {modelo.intercept_}")
print(f"Quando X vale 65, a saída vale: {modelo.predict([[65]])}")
```

1. Treinar
fit(X,y)

2. Ler
w → coef_
b → intercept_

3. Predizer
predict([[65]])

Regressão Linear 20

Figure 3.24: Aula 03 - Coleta de Dados e Regressão Linear

APLICAÇÃO

Exercício em sala

Use os dados abaixo para treinar uma regressão linear e prever a nota de quem estudou 6 horas.

Horas estudadas	1	2	3	4	5
Nota	2.0	3.5	5.1	6.8	8.0

Tarefa 1
Faça o gráfico de dispersão

Tarefa 2
Ajuste o modelo linear

Tarefa 3
Interprete w, b e a previsão

Discussão: a previsão é confiável fora do intervalo observado?

Regressão Linear 21

Figure 3.25: Aula 03 - Coleta de Dados e Regressão Linear




Figure 3.26: Aula 03 - Coleta de Dados e Regressão Linear

Pessoa Observada (i)	Número de Horas sem Dormir (X)	Número de Erros (Y)
1	8	6
2	8	8
3	12	6
4	12	10
5	16	8
6	16	14
7	20	12
8	20	14
9	24	12
10	24	16

- a) Calcule o **coeficiente de correlação linear** de Pearson, interprete e teste sua significância a **5%**.
- b) Ajuste, **teste e interprete o modelo de regressão linear** simples.

No python Comece importando os cabeçalhos: - importe a biblioteca **numpy** para criar vetores de valores - importe a biblioteca **stats** para usar as funções para **linregress** para calcular a regressão linear - importe a biblioteca **stats** para usar as funções para **pearsonr** para calcular o coeficiente de correlação **r**

```
import numpy as np
from scipy import stats
from yt_dlp.extractor import agora
```

Agora precisamos criar uma função para calcular a **regressão linear**

```
def calcular_regressao_linear(x: np.ndarray, y: np.ndarray) -> tuple[float, float, float]:
    """Calcula os parâmetros e o teste de significância da regressão linear simples."""
    print("--- b) Modelo de Regressão Linear Simples ---")
    # Ajustando a reta de regressão e obtendo estatísticas completas
    inclinacao_reta, interceptacao, correlacao_r, valor_p, erro_padrao = stats.linregress(x, y)
    print(f"Coefficiente Angular ( m ): {inclinacao_reta:.4f}")
    print(f"Intercepto ( n ): {interceptacao:.4f}")
    print(f"Equação ajustada: Y_hat = {interceptacao:.4f} + {inclinacao_reta:.4f} * X")
    print(f"P-valor do coeficiente angular (teste do modelo): {valor_p:.5f}")

    if ( valor_p < 0.05):
        print("Conclusão: O modelo de regressão linear é estatisticamente significativo a 5%.")
    else:
        print("Conclusão: O modelo não é estatisticamente significativo.")

    return interceptacao, inclinacao_reta, valor_p
```

Agora precisamos criar uma função para calcular o **coeficiente de correlação**
r

```
def calcular_correlacao_pearson(v_independentes_x: np.ndarray, v_dependentes_y: np.ndarray) -> tuple[float, float]:
    """Calcula o coeficiente de correlação de Pearson e o p-valor correspondente."""
    print("--- a) Coeficiente de Correlação de Pearson e Teste ---")
    coeficiente_de_correlacao_r, valor_de_p = stats.pearsonr(v_independentes_x, v_dependentes_y)

    print(f"Coefficiente de Correlação (r): {coeficiente_de_correlacao_r:.4f}")
    print(f"P-valor da correlação: {valor_de_p:.5f}")

    if ( valor_de_p < 0.05):
        print("Conclusão: Rejeitamos a Hipótese. A correlação é estatisticamente relevante a 5%.")
    else:
        print("Conclusão: Não rejeitamos a Hipótese.\n")
    return coeficiente_de_correlacao_r, valor_de_p
```

Agora vamos definir a ordem de execução das funções:

```
def funcao_principal() -> None:
    # Carregar os valores de X (que é a variável independente) no vetor variaveis_independentes_x
    # X: Número de horas sem dormir
    variaveis_independentes_x = np.array([8, 8, 12, 12, 16, 16, 20, 20, 24, 24])

    # Carregar os valores de Y (que é a variável dependente) no vetor variaveis_dependentes_y
    # Y: Número de erros
```

```

variaveis_dependentes_y = np.array([6, 8, 6, 10, 8, 14, 12, 14, 12, 16])

# Executando a correlação
calcular_correlacao_pearson(variaveis_independentes_x, variaveis_dependentes_y)

# Executando a regressão linear
calcular_regressao_linear(variaveis_independentes_x, variaveis_dependentes_y)

```

Finalmente, vamos iniciar o **fluxo principal** do programa, chamado a **funcao_principal()** que chamará todas as outras na ordem

```

if __name__ == '__main__':
    funcao_principal()

## --- a) Coeficiente de Correlação de Pearson e Teste ---
## Coeficiente de Correlação (r): 0.8015
## P-valor da correlação: 0.00531
## Conclusão: Rejeitamos a Hipótese. A correlação é estatisticamente relevante a 5%.
##
## --- b) Modelo de Regressão Linear Simples ---
## Coeficiente Angular ( m ): 0.4750
## Intercepto ( n ): 3.0000
## Equação ajustada: Y_hat = 3.0000 + 0.4750 * X
## P-valor do coeficiente angular (teste do modelo): 0.00531
## Conclusão: O modelo de regressão linear é estatisticamente significativo a 5%.

```

Como ficou a equação descoberta pela **regressão linear simples** ?

Uma equação de reta segue o formato $y = mx + n$.

$$y = m \text{ ** coeficiente angular } x + n \text{ coeficiente linear}$$

No exercício: - o valor de **m** é dado pelo valor do **coeficiente angular** ; - o valor de **n** é dado pelo valor do **intercepto** ;

Então a equação ficou:

$$y = 0,4750(x) + 3$$

3.1.1.1 Gráfico do Exemplo 00

```

import numpy as np
import matplotlib.pyplot as plt

# Dados do problema
x = np.array([8, 8, 12, 12, 16, 16, 20, 20, 24, 24])
y = np.array([6, 8, 6, 10, 8, 14, 12, 14, 12, 16])

# Configuração do gráfico
plt.figure(figsize=(10, 7))

# Definindo os limites dos eixos começando em 0
plt.xlim(-8, max(x) + 2)

## (-8.0, 26.0)

plt.ylim(-8, max(y) + 2)

## (-8.0, 18.0)

# Configurando a escala unitária (passo de 1 em 1) para os eixos X e Y
plt.xticks(np.arange(0, max(x) + 3, 1))

## ([<matplotlib.axis.XTick object at 0x000001CC61887530>, <matplotlib.axis.XTick object at 0x000001CC61887530>, <matplotlib.axis.XTick object at 0x000001CC61887530>, <matplotlib.axis.XTick object at 0x000001CC61887530>, <matplotlib.axis.XTick object at 0x000001CC61887530>, <matplotlib.axis.XTick object at 0x000001CC61887530>, <matplotlib.axis.XTick object at 0x000001CC61887530>, <matplotlib.axis.XTick object at 0x000001CC61887530>, <matplotlib.axis.XTick object at 0x000001CC61887530>, <matplotlib.axis.XTick object at 0x000001CC61887530>], [0, 8, 12, 16, 20, 24, 28])

plt.yticks(np.arange(0, max(y) + 3, 1))

## ([<matplotlib.axis.YTick object at 0x000001CC61AAC620>, <matplotlib.axis.YTick object at 0x000001CC61AAC620>, <matplotlib.axis.YTick object at 0x000001CC61AAC620>, <matplotlib.axis.YTick object at 0x000001CC61AAC620>, <matplotlib.axis.YTick object at 0x000001CC61AAC620>, <matplotlib.axis.YTick object at 0x000001CC61AAC620>, <matplotlib.axis.YTick object at 0x000001CC61AAC620>, <matplotlib.axis.YTick object at 0x000001CC61AAC620>, <matplotlib.axis.YTick object at 0x000001CC61AAC620>, <matplotlib.axis.YTick object at 0x000001CC61AAC620>], [0, 6, 8, 10, 12, 14, 16, 18])

# Grade padrão em cinza claro para a escala geral
for xtick in np.arange(0, max(x) + 3, 1):
    plt.axvline(xtick, color='gray', linewidth=0.3, linestyle=':', alpha=0.5, zorder=1)

for ytick in np.arange(0, max(y) + 3, 1):
    plt.axhline(ytick, color='gray', linewidth=0.3, linestyle=':', alpha=0.5, zorder=1)

# Projetando linhas vermelhas contínuas sobre os pares ordenados formados pelos vetores x e y
for xi, yi in zip(x, y):
    plt.vlines(xi, 0, yi, color='green', linewidth=0.5, linestyle='--', alpha=0.5, zorder=2)
    plt.hlines(yi, 0, xi, color='green', linewidth=0.5, linestyle='--', alpha=0.5, zorder=2)

# Destacando os eixos principais em (0,0)

```

```
plt.axhline(0, color='black', linewidth=1.2, zorder=3)
plt.axvline(0, color='black', linewidth=1.2, zorder=3)

# Gráfico de dispersão (pontos observados)
plt.scatter(x, y, color='blue', label='Dados Observados', s=60, zorder=5)


# Adicionando rótulos com os pares ordenados (X, Y) em cada ponto
for xi, yi in zip(x, y):
    plt.annotate(f"({xi}, {yi})",
                 (xi, yi),
                 textcoords="offset points",
                 xytext=(0, 8), # Deslocamento vertical do texto em relação ao ponto
                 ha='center',
                 fontsize=8,
                 fontweight='bold',
                 color='darkblue',
                 zorder=6)

# Definindo os pontos para a reta  $y = 0.4750 * x + 3$ 
x_linha = np.linspace(-7, max(x), 100)
y_linha = 0.4750 * x_linha + 3

# Plotando a reta de regressão
plt.plot(x_linha, y_linha, color='red', linestyle='--', linewidth=2, label='Reta:  $Y = 0.4750X + 3$ ')

# Rótulos e formatação
plt.title('Gráfico com Pares Ordenados (X, Y) Identificados nos Pontos', fontsize=12, fontweight='bold')
plt.xlabel('Número de Horas sem Dormir (X)', fontsize=10)
plt.ylabel('Número de Erros (Y)', fontsize=10)
plt.legend()

# Exibir o gráfico
plt.show()
```



3.1.2 Testes de Multipla-Escolha:

3.2 Questão 1

Questão 1

Na **Regressão Linear simples**, o modelo é representado por: $\hat{y} = w(x) + b$
 Assinale a alternativa correta sobre os **parâmetros** w e b .

- A) w representa o erro do modelo e b representa o valor real observado.
- B) w representa a inclinação da reta e b representa o intercepto/deslocamento vertical.
- C) w representa a variável dependente e b representa a variável independente.
- D) w representa o número de observações e b representa o número de previsões.
- E) w e b são sempre fornecidos previamente e não são aprendidos pelo modelo.

Questão 2

Na **programação tradicional**, conhecemos uma entrada $\mathbf{x}$ e uma função $\mathbf{f}(\mathbf{x})$, e então calculamos a saída $\mathbf{y}$.

No **aprendizado de máquina supervisionado**, durante o treinamento, a lógica é diferente. Assinale a alternativa que melhor representa esse processo.

- A) Dados + modelo conhecido $\rightarrow$ resposta.
 - B) Modelo + resposta $\rightarrow$ dados.
 - C) Dados + respostas conhecidas $\rightarrow$ aprendizado de um modelo.
 - D) Dados sem respostas $\rightarrow$ resultado exato.
 - E) Apenas a variável x é suficiente para descobrir qualquer modelo.
-

3.3 Questão 3

Questão 3

Considere o modelo de **Regressão Linear**:

$$\hat{y} = 4,7x + 28$$

onde:

- x representa a área do imóvel em m^2 ;
- $\hat{y}$ representa o preço estimado em milhares de reais.

Para um apartamento com $65 m^2$:

$$\hat{y} = 4,7(65) + 28$$

$$\hat{y} = 333,5$$

Analise as afirmações:

I. O preço estimado para um apartamento de $65 m^2$ é de aproximadamente **R\$ 333,5 mil**.

II. O coeficiente 4,7 indica que, segundo o modelo, cada aumento de $1 m^2$ está associado a um aumento estimado de **R\$ 4,7 mil**.

III. O valor 28 corresponde à inclinação da reta.

Assinale a alternativa **correta**.

- A) Apenas I está correta.
 - B) Apenas II está correta.
 - C) Apenas I e II estão corretas.
 - D) Apenas II e III estão corretas.
 - E) I, II e III estão corretas.
-

3.4 Questão 4

Questão 4

Considere os seguintes **pares ordenados** (x, y) , ou ainda **(entrada, saída)**, observados:

$(40, 220)$, $(50, 260)$, $(60, 310)$, $(70, 350)$, $(80, 410)$

A partir desses dados, foi obtido o **modelo**:

$$\hat{y} = 4,7x + 28$$

Analise as afirmações:

I. A variável x representa a área do apartamento.

II. A variável $\hat{y}$ representa o preço estimado pelo modelo.

III. Depois que o modelo foi encontrado, ele pode ser utilizado para estimar o preço de um apartamento com área diferente das que aparecem na tabela, como $65 m^2$.

Assinale a alternativa **correta**.

A) Apenas I está correta.

B) Apenas I e II estão corretas.

C) Apenas II e III estão corretas.

D) Apenas I e III estão corretas.

E) I, II e III estão corretas.

Chapter 4

Gabarito

Questão	Resposta correta
1	B
2	C
3	C
4	E

Também retirei da Questão 2 o comentário explicativo após o gabarito, para manter todas as questões no mesmo padrão de prova.

Chapter 5

- Organização e Preparação dos Dados, Regressão Logística e KNN

5.1 - Exercícios - Organização e Preparação dos Dados, Regressão Logística e KNN

5.1.1 Organização e Preparação de Dados: População, Estrato , proporção e Amostra

A regra é:

$$n_h = n \cdot \frac{N_h}{N}$$

onde (N) é o tamanho da população, (N_h) é o tamanho do estrato, (n) é o tamanho total da amostra e (n_h) é a quantidade de elementos sorteados naquele estrato.

5.1.1.1 1. Alunos de uma universidade

População: 10.000 alunos. **Amostra desejada:** 1.000 alunos.

Estrato	População no estrato	Proporção	Amostra proporcional
Engenharia	3.000	30%	300
Administração	2.500	25%	_____
Direito	2.000	20%	_____
Saúde	1.500	15%	_____
Outros cursos	1.000	10%	_____
Total	10.000	100%	1.000

Por exemplo:

$$n_{\text{Engenharia}} = 1000 \cdot \frac{3000}{10000} = 300$$

5.1.1.2 2. Funcionários de uma empresa

População: 2.000 funcionários. **Amostra:** 200 funcionários.

Estrato	População	Proporção	Amostra
Produção	900	45%	90
Administrativo	400	20%	_____
Comercial	300	15%	_____
Tecnologia	250	12,5%	_____
Diretoria/Gestão	150	7,5%	_____
Total	2.000	100%	200

Assim, embora a área de Produção tenha muito mais funcionários, ela não domina arbitrariamente a pesquisa: sua participação na amostra permanece igual à sua participação na população.

5.1.1.3 3. Moradores de uma cidade

População: 50.000 moradores. **Amostra:** 1.000 moradores.

Estratificação por faixa etária:

Estrato	População	Proporção	Amostra
0–17 anos	10.000	20%	200
18–29 anos	8.000	16%	_____
30–44 anos	12.000	24%	_____
45–59 anos	11.000	22%	_____
60 anos ou mais	9.000	18%	_____
Total	50.000	100%	1.000

Para a faixa de 30 a 44 anos:

$$n_h = 1000 \cdot \frac{12000}{50000} = 240$$

5.1.1.4 4. Imagens do CIFAR-10

Aqui temos um exemplo particularmente simples porque o CIFAR-10 é **balanceado entre as classes**.

População: 60.000 imagens. **Amostra:** 6.000 imagens.

Cada uma das 10 classes possui 6.000 imagens.

Estrato — classe	População	Proporção	Amostra
airplane	6.000	10%	600
automobile	6.000	10%	_____
bird	6.000	10%	_____
cat	6.000	10%	_____
deer	6.000	10%	_____
dog	6.000	10%	_____
frog	6.000	10%	_____
horse	6.000	10%	_____
ship	6.000	10%	_____
truck	6.000	10%	_____
Total	60.000	100%	6.000

Neste caso:

$$6000 \cdot \frac{6000}{60000} = 600$$

Como todas as classes possuem a mesma quantidade de elementos, a amostra proporcional também fica perfeitamente balanceada.

5.1.1.5 5. Domicílios de um município

População: 20.000 domicílios. **Amostra:** 1.000 domicílios.

Estratificação por região do município:

Estrato	Domicílios	Proporção	Amostra
Centro	4.000	20%	200
Norte	5.000	25%	_____
Sul	3.000	15%	_____
Leste	6.000	30%	_____
Oeste	2.000	10%	_____
Total	20.000	100%	1.000

Por exemplo, para a região Leste:

$$n_{\text{Leste}} = 1000 \cdot \frac{6000}{20000} = 300$$

O ponto central para mostrar no slide é:

A proporção de cada estrato na amostra é igual à sua proporção na população

5.1.1.6 6. Pacientes de uma clínica — população balanceada

População: 4.000 pacientes. **Amostra:** 400 pacientes.

Estratificação por tipo de atendimento:

Estrato	População	Proporção	Amostra
Cardiologia	1.000	25%	100
Ortopedia	1.000	25%	_____
Dermatologia	1.000	25%	_____
Oftalmologia	1.000	25%	_____
Total	4.000	100%	400

Por exemplo:

$$n_{\text{Cardiologia}} = 400 \cdot \frac{1000}{4000} = 100$$

5.1. - EXERCÍCIOS - ORGANIZAÇÃO E PREPARAÇÃO DOS DADOS, REGRESSÃO LOGÍSTICA E KNN45

Como todos os estratos têm o mesmo tamanho, a amostra também fica igualmente distribuída.

5.1.1.7 7. Produtos de um estoque — população balanceada

População: 10.000 produtos. **Amostra:** 1.000 produtos.

Estratificação por categoria:

Estrato	População	Proporção	Amostra
Eletrônicos	2.000	20%	200
Alimentos	2.000	20%	_____
Vestuário	2.000	20%	_____
Higiene	2.000	20%	_____
Papelaria	2.000	20%	_____
Total	10.000	100%	1.000

Para cada categoria:

$$1000 \cdot \frac{2000}{10000} = 200$$

Esse é outro caso de população perfeitamente balanceada.

5.1.2 8. Imagens de um dataset de classificação — população balanceada

População: 30.000 imagens. **Amostra:** 3.000 imagens.

Considere um dataset com 6 classes:

Estrato — classe	População	Proporção	Amostra
Cachorro	5.000	16,67%	500
Gato	5.000	16,67%	_____
Cavalo	5.000	16,67%	_____
Pássaro	5.000	16,67%	_____
Peixe	5.000	16,67%	_____
Coelho	5.000	16,67%	_____

Estrato — classe	População	Proporção	Amostra
Total	30.000	100%	3.000

Para a classe “Cachorro”:

$$n_h = 3000 \cdot \frac{5000}{30000} = 500$$

Todas as classes possuem a mesma representatividade.

5.1.3 9. Clientes de um banco — população não balanceada

População: 100.000 clientes. **Amostra:** 2.000 clientes.

Estratificação por faixa de renda:

Estrato	População	Proporção	Amostra
Até R\$ 2 mil	45.000	45%	900
R\$ 2 mil a R\$ 5 mil	30.000	30%	_____
R\$ 5 mil a R\$ 10 mil	15.000	15%	_____
R\$ 10 mil a R\$ 20 mil	7.000	7%	_____
Acima de R\$ 20 mil	3.000	3%	_____
Total	100.000	100%	2.000

Para o primeiro estrato:

$$n_h = 2000 \cdot \frac{45000}{100000} = 900$$

Aqui os estratos possuem tamanhos bastante diferentes, mas a amostra preserva essas diferenças proporcionalmente.

5.1.4 10. Dataset de detecção de fraude — população não balanceada

População: 50.000 transações. **Amostra:** 5.000 transações.

Estratificação pelo tipo de transação:

Estrato	População	Proporção	Amostra
Transações normais	42.500	85%	4.250
Fraudes leves	4.000	8%	_____
Fraudes moderadas	2.000	4%	_____
Fraudes graves	1.000	2%	_____
Fraudes críticas	500	1%	_____
Total	50.000	100%	5.000

Para as fraudes críticas:

$$n_{\text{críticas}} = 5000 \cdot \frac{500}{50000} = 50$$

OBS: **classes raras continuam raras na amostra proporcional.**

Assim, podemos resumir os exemplos 6–10 como:

Exemplo	População	Situação
6	Pacientes por especialidade	Balanceada
7	Produtos por categoria	Balanceada
8	Dataset de imagens	Balanceada
9	Clientes por faixa de renda	Não balanceada
10	Transações financeiras	Não balanceada

5.1.5 TESTES DE MULTIPLA ESCOLHA

5.1.6 Estratos , Proporções e Amostras

Questão 5

Uma população é composta por **40% de indivíduos da classe A** e **60% da classe B**. Deseja-se retirar uma amostra de **100 indivíduos**.

Qual alternativa descreve corretamente uma **amostra proporcional** e uma **amostra balanceada**, respectivamente?

A) Proporcional: 50 indivíduos de A e 50 de B; Balanceada: 40 de A e 60 de B.

Questão 5

- B) Proporcional: 40 indivíduos de A e 60 de B; Balanceada: 50 de A e 50 de B.
 C) Proporcional: 60 indivíduos de A e 40 de B; Balanceada: 40 de A e 60 de B.
 D) Proporcional: 40 indivíduos de A e 40 de B; Balanceada: 60 de A e 40 de B.
 E) Proporcional e balanceada são conceitos equivalentes, portanto ambas devem possuir 50 indivíduos de cada classe.
-

5.1.7 Questão 6 KNN

Questão 6

Sobre o algoritmo **K-Nearest Neighbors (KNN)**, assinale a alternativa correta.

- A) O KNN é um algoritmo paramétrico que precisa determinar obrigatoriamente os parâmetros w e b .
 B) O KNN utiliza exclusivamente uma função sigmoide para calcular a classe de uma nova observação.
 C) O KNN é um algoritmo **não paramétrico** que pode classificar uma nova observação considerando a distância entre ela e as observações conhecidas.
 D) No KNN, o valor de K representa o número de atributos existentes no conjunto de dados.
 E) O KNN somente pode ser utilizado quando existem exatamente duas classes.
-

5.1.8 Questão 7 - Regressão Logística

Questão 7 — Exercício resolvido: Regressão Logística

Considere o modelo de **Regressão Logística** apresentado em aula:

$$z = wX + b \text{ com:}$$

$$w = 1,19$$

e

$$b = -6,52$$

Para um aluno que estudou **6 horas**, temos:

$$z = 1,19(6) - 6,52$$

$$z = 7,14 - 6,52$$

$$z = 0,62$$

Aplicando a **função logística (sigmoide)**:

$$P(Y = 1 | X) = \frac{1}{1 + e^{-z}}$$

temos aproximadamente:

$$P(Y = 1 | X = 6) \approx 0,65$$

ou seja, aproximadamente **65%**.

Considerando um limiar de classificação de **50%**, analise as afirmações:

I. Como a probabilidade calculada é aproximadamente 65%, o aluno será classificado como **Aprovado**.

II. O valor $z = 0,62$ corresponde diretamente a uma probabilidade de 62%.

III. A função sigmoide transforma o valor de z em um número entre 0 e 1, que pode ser interpretado como probabilidade.

Assinale a alternativa **correta**.

A) Apenas I está correta.

B) Apenas II está correta.

C) Apenas I e II estão corretas.

D) Apenas I e III estão corretas.

E) I, II e III estão corretas.

5.1.9 Questão 8 - KNN

Questão 8

Considere uma nova observação:

$$X = (4, 4)$$

e quatro observações já classificadas:

A: (2, 3) — Azul ; **B:** (3, 4) — Azul ; **C:** (5, 4) — Vermelho ; **D:** (8, 8) — Vermelho ;

Utilizando a **distância Euclidiana**:

$$d(P, X) = \sqrt{(x_P - x_X)^2 + (y_P - y_X)^2}$$

temos:

$$d(A, X) = \sqrt{(2 - 4)^2 + (3 - 4)^2} = \sqrt{5} \approx 2,24$$

$$d(B, X) = \sqrt{(3 - 4)^2 + (4 - 4)^2} = 1$$

$$d(C, X) = \sqrt{(5 - 4)^2 + (4 - 4)^2} = 1$$

$$d(D, X) = \sqrt{(8 - 4)^2 + (8 - 4)^2} = \sqrt{32} \approx 5,66$$

Portanto, considerando $K = 3$, os três vizinhos mais próximos são **B, C e A**, cujas classes são:

Azul, Vermelho, Azul.

Analise as afirmações:

I. Para $K = 3$, a nova observação será classificada como **Azul**.

II. O ponto D possui menor distância até X do que o ponto A.

III. No KNN com $K = 3$, são considerados os três pontos que apresentam as menores distâncias em relação à nova observação.

Assinale a alternativa **correta**.

A) Apenas I está correta.

B) Apenas II está correta.

C) Apenas I e II estão corretas.

D) Apenas II e III estão corretas.

E) Apenas I e III estão corretas.

Chapter 6

Gabarito

Questão	Resposta correta
5	B
6	C
7	D
8	E

Chapter 7

- Análise de Dados: Dilema Viés-Variância e Métricas de Avaliação

7.1 - Exercícios - Análise de Dados: Dilema Viés-Variância e Métricas de Avaliação

Chapter 8

- Relatórios K.P.I. - Avaliação de Modelos e Árvores de Decisão

8.1 - Exercícios - Relatórios K.P.I. - Avaliação de Modelos e Árvores de Decisão

Chapter 9

- Business Intelligence: Random Forest e Ensemble Learning

9.1 - Exercícios - Business Intelligence: Random Forest e Ensemble Learning

Chapter 10

- Big Data e Support Vector Machines

10.1 - Exercícios - Big Data e Support Vector Machines

Chapter 11

- Data Driven Decision Making e Redução de Dimensionalidade

11.1 - Exercícios - Data Driven Decision Making e Redução de Dimensionalidade

Chapter 12

- Modelos de Gestão de Risco e Técnicas de Agrupamento

12.1 - Exercícios - Modelos de Gestão de Risco e Técnicas de Agrupamento

Chapter 13

- Inteligência Artificial, Análise Preditiva e Seleção de Características

13.1 - Exercícios - Inteligência Artificial, Análise Preditiva e Seleção de Características

Chapter 14

- Monitoramento Contínuo e Ciclo de Vida de Modelos de Machine Learning

14.1 - Exercícios - Monitoramento Contínuo e Ciclo de Vida de Modelos de Machine Learning

Bibliography

Joel Grus. *Ciência de Dados do Zero: Primeiros Princípios com Python*. O'Reilly Media, Sebastopol, CA, 1 edition, 2015. ISBN 978-1-491-90142-7. URL <https://dokumen.pub/download/data-science-do-zero-primeiras-regras-com-o-python-9788550803876-9781491901427.html>.